Phân tích cảm xúc đánh giá sản phẩm Amazon Fine Food

Bộ phân loại cảm xúc ba lớp bằng học sâu

Báo cáo bài tập lớn môn Nhập môn Học sâu

Giảng viên: TS. Trần Việt Trung

Học viên

Nguyễn Tuệ Lâm 20261207M

Ngày 10 tháng 11 năm 2026

Mục lục

1 Giới thiệu **3**
- 1.1 Bối cảnh của dự án . . . 3
- 1.2 Phát biểu vấn đề . . . 3
- 1.3 Câu hỏi nghiên cứu . . . 3
- 1.4 Mục tiêu dự án . . . 4
- 1.5 Phạm vi và giới hạn . . . 4
- 1.6 Cấu trúc báo cáo . . . 4

2 Phát biểu bài toán và hướng tiếp cận **5**
- 2.1 Nền tảng đánh giá và theo dõi cảm xúc . . . 5
- 2.2 Cảm xúc từ số sao: nhãn yếu . . . 5
- 2.3 Mục tiêu nghiệp vụ . . . 5
- 2.4 Độ đo đánh giá . . . 5
- 2.5 Tiêu chí thành công . . . 6
- 2.6 Từ mục tiêu đến bài toán phân tích . . . 6
- 2.7 Hướng tiếp cận . . . 6
- 2.8 Lộ trình thực hiện . . . 6

3 Bộ dữ liệu và đặc tả dữ liệu **8**
- 3.1 Nguồn và cách thu thập dữ liệu . . . 8
- 3.2 Đặc điểm và hạn chế của bộ dữ liệu . . . 8
- 3.3 Lược đồ dữ liệu thô . . . 8
- 3.4 Tên cột trong quy trình xử lý . . . 9
- 3.5 Quy ước giá trị . . . 9
- 3.6 Thông tin không có . . . 9
- 3.7 Thiết kế bảng dữ liệu phân tích . . . 9

4 Tìm hiểu dữ liệu **10**
- 4.1 Mục tiêu . . . 10
- 4.2 Tổng quan bộ dữ liệu . . . 10
- 4.3 Phân bố lớp . . . 10
- 4.4 Độ dài văn bản . . . 10
- 4.5 Thay đổi theo thời gian . . . 11
- 4.6 Người dùng, sản phẩm và độ hữu ích . . . 11
- 4.7 Nhiễu trong văn bản . . . 12
- 4.8 Từ vựng của từng lớp . . . 12
- 4.9 Quyết định thiết kế cho bước chuẩn bị dữ liệu . . . 12

5 Chuẩn bị dữ liệu **13**
- 5.1 Mục tiêu . . . 13
- 5.2 Làm sạch dữ liệu . . . 13
- 5.3 Tạo văn bản đầu vào của mô hình . . . 14

5.4 Tạo nhãn . . . 14
5.5 Chia train, validation và test . . . 14
5.6 Trọng số lớp . . . 15
5.7 Phòng tránh rò rỉ và cách chia ngẫu nhiên . . . 15
5.8 Kết luận . . . 16

6 Xây dựng mô hình **17**
6.1 Mục tiêu . . . 17
6.2 Nền tảng: vì sao dùng mô hình chuỗi và Transformer . . . 17
6.3 BiLSTM với attention . . . 18
6.4 Fine-tune BERT . . . 20
6.5 Tóm tắt các mô hình . . . 20

7 Đánh giá **21**
7.1 Mục tiêu . . . 21
7.2 Kết quả trên toàn bộ tập test . . . 21
7.3 Có phải lớp neutral là vấn đề? . . . 22
7.4 Hiệu năng theo độ dài review . . . 22
7.5 Khoảng bootstrap cho chênh lệch . . . 22
7.6 Hiệu chỉnh ngưỡng cho lớp neutral . . . 22
7.7 Phân tích lỗi và ví dụ . . . 23
7.8 Hạn chế . . . 23

8 Kết luận **25**
8.1 Tổng kết . . . 25
8.2 Hạn chế . . . 25
8.3 Hướng phát triển . . . 25
8.4 Khả năng tái lập . . . 26

Chương 1

Giới thiệu

1.1 Bối cảnh của dự án

Các cửa hàng trực tuyến nhận hàng nghìn đánh giá sản phẩm mỗi ngày. Đọc thủ công là không khả thi, trong khi cảm xúc trong các đánh giá cho người bán biết sản phẩm nào làm khách hàng thất vọng và sản phẩm nào được khen.

Biến văn bản đó thành một tín hiệu đếm được là việc khó, vì số sao và nội dung review không phải lúc nào cũng khớp nhau. Một review có tiêu đề *"Not as Advertised"* và mở đầu bằng "Product arrived labeled as Jumbo Salted Peanuts…the peanuts were actually small sized unsalted" là review tiêu cực mà không chứa một từ nào mang nghĩa tiêu cực mạnh. Bộ phân loại phải đọc câu, không chỉ đếm từ.

Dự án dùng bộ dữ liệu Amazon Fine Food Reviews [1, 2]: 568.454 review đăng từ tháng 10/1999 đến tháng 10/2012, mỗi review kèm số sao. Số sao cho ta nhãn mà không cần gán nhãn thủ công, nhưng phân bố bị lệch: sau khi làm sạch, khoảng 78% review là positive và chỉ 7,6% là neutral. Một bộ phân loại luôn trả lời *positive* đạt khoảng 78% accuracy mà không nhận biết được gì về hai lớp còn lại. Vì vậy các mô hình học sâu đọc văn bản theo ngữ cảnh được kiểm tra trên một bài toán mà lối tắt hiển nhiên đã rất mạnh.

1.2 Phát biểu vấn đề

- **Khó đọc cảm xúc từ văn bản.** Cảm xúc phụ thuộc vào phủ định ("not bad"), đối lập ("good but…") và ngữ cảnh, nên đếm từ là chưa đủ. Mô hình phải dùng thứ tự từ và ngữ cảnh.
- **Nhãn mất cân bằng và chỉ gần đúng.** Nhãn suy ra từ số sao, không phải do con người gán, và lớp neutral (3 sao) hiếm và mơ hồ. Một mô hình có thể có accuracy cao mà vẫn sai ở các lớp thiểu số.

1.3 Câu hỏi nghiên cứu

1. Làm thế nào biến các review thô và số sao thành một bộ dữ liệu có nhãn sạch, trong đó cùng một văn bản không xuất hiện ở cả tập train và tập test?
2. Các lớp lệch đến mức nào và review dài bao nhiêu, và những điều này gợi ý gì cho độ đo, hàm mất mát và độ dài chuỗi?
3. Một Transformer tiền huấn luyện được fine-tune trên dữ liệu này (BERT) cải thiện được bao nhiêu so với mạng hồi quy huấn luyện từ đầu (BiLSTM với attention)?

4. Hai mô hình đã huấn luyện cải thiện được bao nhiêu so với quy tắc luôn đoán *positive*, và ở những lớp nào?

5. Các mô hình sai ở đâu, đặc biệt ở lớp neutral và ở những review có nội dung mâu thuẫn với số sao?

1.4 Mục tiêu dự án

Xây dựng và so sánh các bộ phân loại học sâu gán một trong ba nhãn cảm xúc (negative, neutral, positive) cho văn bản của một review thực phẩm, dùng bộ dữ liệu sạch, không rò rỉ, và cách đánh giá không bị đánh lừa bởi lớp positive chiếm đa số.

1.5 Phạm vi và giới hạn

Trong phạm vi: phân loại cảm xúc ba lớp cho văn bản review tiếng Anh, làm sạch và chia dữ liệu, BiLSTM với attention huấn luyện từ đầu, bộ mã hoá BERT được fine-tune, và quy tắc luôn đoán positive làm mốc tham chiếu.

Ngoài phạm vi / không khẳng định:

- Cảm xúc do con người gán nhãn: nhãn đến từ số sao nên một số nhãn sai ngay từ đầu (Mục 2.2).
- Dự đoán cảm xúc của các review *trong tương lai*: cách chia là ngẫu nhiên, không theo thời gian (Mục 5.7).
- Cảm xúc theo khía cạnh (đặc điểm nào của sản phẩm được khen hay chê), các ngôn ngữ khác và các lĩnh vực sản phẩm khác.
- Một dịch vụ đã triển khai.

1.6 Cấu trúc báo cáo

Báo cáo được tổ chức thành các chương theo đúng thứ tự công việc đã làm. Các chương gồm:

1. **Giới thiệu**: bối cảnh, phát biểu vấn đề, câu hỏi nghiên cứu, mục tiêu và phạm vi.
2. **Phát biểu bài toán và hướng tiếp cận** (Chương 2): nhãn yếu, tiêu chí thành công, độ đo và hướng phân tích.
3. **Bộ dữ liệu và đặc tả dữ liệu** (Chương 3): bộ Amazon Fine Food Reviews, lược đồ, quy ước và hạn chế.
4. **Tìm hiểu dữ liệu** (Chương 4): phân bố lớp, độ dài văn bản, thay đổi theo thời gian, người dùng, nhiễu và từ vựng, cùng các quyết định thiết kế rút ra.
5. **Chuẩn bị dữ liệu** (Chương 5): làm sạch, văn bản đầu vào của mô hình, chia phân tầng, tập con test cố định và trọng số lớp.
6. **Xây dựng mô hình** (Chương 6): BiLSTM với attention và BERT được fine-tune.
7. **Đánh giá** (Chương 7): kết quả trên tập test, khoảng tin cậy, lớp neutral, độ dài review, hiệu chỉnh ngưỡng, lỗi và hạn chế.
8. **Kết luận** (Chương 8): tổng kết, hạn chế, hướng phát triển và khả năng tái lập.

Chương 2

Phát biểu bài toán và hướng tiếp cận

2.1 Nền tảng đánh giá và theo dõi cảm xúc

Một cửa hàng bán qua sàn thương mại điện tử nhận phản hồi dưới dạng văn bản tự do. Mỗi review cho thấy khách hàng cảm thấy thế nào về sản phẩm, và một tập review cho thấy sản phẩm nào được khen, sản phẩm nào bị chê. Đếm review theo cảm xúc biến văn bản đó thành một con số có thể theo dõi theo thời gian và so sánh giữa các sản phẩm.

2.2 Cảm xúc từ số sao: nhãn yếu

Bộ dữ liệu không có nhãn cảm xúc, chỉ có số sao (1–5) do người viết chọn. Số sao được dùng làm **nhãn yếu**: rẻ để có nhưng chỉ gần đúng. Phép ánh xạ được cố định một lần:

Số sao (`Score`)	1	2	3	4	5
Nhãn	negative	negative	neutral	positive	positive

Người viết có thể chấm năm sao nhưng vẫn viết lời phàn nàn, nên một số nhãn sai ngay từ đầu. Điều này được coi là một đặc tính của dữ liệu, không bị che giấu, và được xem xét khi phân tích lỗi của các mô hình.

2.3 Mục tiêu nghiệp vụ

Mục tiêu là phân loại cảm xúc của một review chỉ từ văn bản của nó. Các mục tiêu cụ thể là:

- **Chuẩn bị bộ dữ liệu đáng tin:** loại các review lặp trước khi chia, để việc đánh giá đo khả năng tổng quát hoá chứ không đo khả năng ghi nhớ.
- **Xây dựng hai bộ phân loại nơ-ron:** BiLSTM với attention huấn luyện từ đầu, và bộ mã hoá BERT được fine-tune trên cùng dữ liệu.
- **So sánh công bằng:** trên cùng các review test, với quy tắc luôn đoán positive làm mốc tham chiếu.

2.4 Độ đo đánh giá

Accuracy là chưa đủ ở đây, vì luôn đoán *positive* đã đạt khoảng 78%. Với mỗi lớp c, precision, recall và F1 là

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \qquad F1_c = \frac{2\,P_c R_c}{P_c + R_c},$$

và độ đo chính là **Macro-F1**, trung bình không trọng số của ba lớp:

$$\text{Macro-F1} = \frac{1}{3}\sum_{c} F1_c.$$

Mỗi lớp có trọng số như nhau, nên lớp neutral nhỏ nặng bằng lớp positive lớn. Báo cáo cũng nêu accuracy, F1 theo trọng số, F1 từng lớp, ma trận nhầm lẫn, thời gian huấn luyện và số tham số.

2.5 Tiêu chí thành công

Thành công được định nghĩa **tương đối so với các phương án đơn giản**, không đặt các ngưỡng tuyệt đối tuỳ ý:

Mức	Tiêu chí (đánh giá trên tập test chưa từng thấy)
Dự đoán	Mỗi mô hình đã huấn luyện có Macro-F1 cao hơn quy tắc luôn đoán positive (khoảng 0,29).
Học chuyển giao	Mô hình BERT được fine-tune có Macro-F1 cao hơn BiLSTM huấn luyện từ đầu, và khoảng bootstrap ghép cặp của chênh lệch không chứa 0.
Lớp thiểu số	F1 của lớp negative và neutral được báo cáo riêng và lớn hơn 0 với mọi mô hình.

2.6 Từ mục tiêu đến bài toán phân tích

Đầu vào là văn bản tiếng Anh của một review, gồm tiêu đề ngắn (`Summary`) và nội dung (`Text`). Đầu ra là một nhãn $y \in \{\text{negative}, \text{neutral}, \text{positive}\}$. Nhiệm vụ là học một hàm f_θ từ văn bản sang $\{0, 1, 2\}$ bằng cách cực tiểu hoá hàm mất mát cross-entropy có trọng số lớp trên tập train (Mục 5.6).

2.7 Hướng tiếp cận

Review thô (568.454 dòng)
↓
Làm sạch: loại review lặp và dòng không hợp lệ
↓
Văn bản đầu vào và nhãn: tiêu đề + nội dung, nhãn từ số sao
↓
Chia phân tầng: train / validation / test, kèm một tập con test cố định
↓
Huấn luyện: BiLSTM với attention; fine-tune BERT; loss có trọng số lớp
↓
Đánh giá: Macro-F1, khoảng tin cậy bootstrap, phân tích lỗi

2.8 Lộ trình thực hiện

Hướng tiếp cận được thực hiện thành một chuỗi bước, mỗi bước nằm trong một chương:

- **Đặc tả dữ liệu** (Chương 3): nguồn, lược đồ, quy ước và những gì không có.

- **Tìm hiểu dữ liệu** (Chương 4): cân bằng lớp, độ dài, thời gian, nhiễu, từ vựng; những điều này quyết định độ đo, giới hạn độ dài chuỗi và quy tắc làm sạch.
- **Chuẩn bị dữ liệu** (Chương 5): làm sạch, tạo văn bản đầu vào, chia dữ liệu và tính trọng số lớp.
- **Xây dựng mô hình và đánh giá**: BiLSTM với attention, fine-tune BERT (Chương 6) và so sánh các mô hình (Chương 7).

Chương 3

Bộ dữ liệu và đặc tả dữ liệu

3.1 Nguồn và cách thu thập dữ liệu

Dự án dùng bộ dữ liệu công khai **Amazon Fine Food Reviews**, do McAuley và Leskovec [1] thu thập và được phân phối trên Kaggle [2]. Đây là một bản trích lịch sử các review thực phẩm đăng trên Amazon từ tháng 10/1999 đến tháng 10/2012. Dữ liệu được đọc từ một file CSV duy nhất, khoảng 300 MB, để kiểm tra, làm sạch và xây dựng mô hình.

3.2 Đặc điểm và hạn chế của bộ dữ liệu

- **Nhãn yếu.** Tín hiệu cảm xúc duy nhất là số sao, và số sao không phải lúc nào cũng khớp với văn bản (Mục 2.2).
- **Review lặp.** Amazon dùng chung một review cho các biến thể (hương vị, kích cỡ) của một sản phẩm, nên cùng một review xuất hiện dưới nhiều mã sản phẩm (Mục 5.2).
- **Một lĩnh vực.** Mọi review đều về thực phẩm, nên kết quả không nhất thiết áp dụng cho đồ điện tử, sách hay phim.
- **Thay đổi theo thời gian.** Số lượng, điểm trung bình và tỉ lệ review negative đều thay đổi từ 2003 đến 2012 (Mục 4.5).

3.3 Lược đồ dữ liệu thô

Dữ liệu thô là một bảng phẳng gồm 568.454 dòng và 10 cột; mỗi dòng là một review.

Cột	Kiểu	Mô tả
`Id`	số nguyên	Số thứ tự dòng.
`ProductId`	chuỗi	Mã sản phẩm.
`UserId`	chuỗi	Mã người dùng.
`ProfileName`	chuỗi	Tên hiển thị của người dùng; thiếu ở 26 dòng.
`HelpfulnessNumerator`	số nguyên	Số người thấy review hữu ích.
`HelpfulnessDenominator`	số nguyên	Số người đã bình chọn (hữu ích hoặc không).
`Score`	số nguyên	Số sao từ 1 đến 5; nguồn của nhãn.
`Time`	số nguyên	Thời điểm đăng, dạng Unix timestamp.
`Summary`	chuỗi	Tiêu đề ngắn của review; thiếu ở 27 dòng.
`Text`	chuỗi	Nội dung review; đầy đủ.

3.4 Tên cột trong quy trình xử lý

Các cột thô giữ nguyên tên trong quy trình. Bốn cột được suy ra hoặc ghép từ chúng:

Cột thô	Tên trong quy trình	Ghi chú
`Score`	`label`	0, 1, 2 tương ứng negative, neutral, positive (Mục 2.2)
`Score`	`sentiment`	Nhãn dưới dạng chữ, cho bảng và biểu đồ dễ đọc
`Time`	`date`	Unix timestamp đổi sang ngày
`Summary`, `Text`	`text`	Đầu vào của mô hình: tiêu đề đã làm sạch nối với nội dung đã làm sạch (Mục 5.3)

3.5 Quy ước giá trị

Ba quy ước xuất hiện xuyên suốt báo cáo:

- **Các cột Helpfulness.** Amazon hiển thị dòng như "12 of 15 people found this review helpful", tương ứng `HelpfulnessNumerator` = 12 và `HelpfulnessDenominator` = 15. Vì tử số là một phần của mẫu số nên nó không bao giờ lớn hơn mẫu số. Hai cột này chỉ dùng để kiểm tra chất lượng dữ liệu (Mục 5.2) và cho một biểu đồ khám phá (Mục 4.6); chúng *không* là đầu vào của mô hình, vì review vừa đăng chưa có lượt bình chọn nào.
- **Tiêu đề bị thiếu.** `Summary` bị thiếu được thay bằng chuỗi rỗng; dòng vẫn được giữ lại.
- **Một dòng, một review.** Sau khi làm sạch, mỗi dòng là một review có văn bản duy nhất. Các cột người dùng và sản phẩm chỉ dùng để nhận diện tác giả và mặt hàng trong phần phân tích mô tả, không là đầu vào của mô hình.

3.6 Thông tin không có

Bộ dữ liệu không có nhãn cảm xúc do con người gán, không có danh mục sản phẩm, không có thông tin về người viết ngoài mã ẩn danh và tên hiển thị, và không có cách chia train/test định sẵn. Vì vậy cách chia trong Chương 5 do dự án tự thực hiện.

3.7 Thiết kế bảng dữ liệu phân tích

Bảng dữ liệu cho mô hình có mỗi dòng là một review: văn bản đầu vào, nhãn và số sao gốc. Bảng được xây dựng trong Chương 5 từ bảng đã làm sạch ở Mục 5.2.

Chương 4

Tìm hiểu dữ liệu

4.1 Mục tiêu

Tìm hiểu dữ liệu và Chuẩn bị dữ liệu (Chương 5) là một mạch liền: hiểu dữ liệu, rút ra các phát hiện về review, rồi biến chúng thành quyết định xây dựng bộ dữ liệu cho mô hình, gồm độ đo, đầu vào, cách chia và hàm mất mát. Câu hỏi nghiệp vụ của chương này là những tính chất nào của dữ liệu phải định hình mô hình và cách đánh giá.

Chương này gồm nửa đầu của mạch đó: tổng quan dữ liệu (Mục 4.2), phân bố lớp (Mục 4.3), độ dài văn bản (Mục 4.4), thay đổi theo thời gian (Mục 4.5), người dùng, sản phẩm và độ hữu ích (Mục 4.6), nhiễu trong văn bản (Mục 4.7) và từ vựng của từng lớp (Mục 4.8). Chương kết thúc bằng các quyết định thiết kế (Mục 4.9) mà Chương 5 thực hiện. Trừ khi nói khác, mọi con số đo trên bảng đã làm sạch gồm 393.577 review ở Mục 5.2.

4.2 Tổng quan bộ dữ liệu

Chỉ số	Giá trị
Số dòng trong file thô	568.454
Số dòng sau làm sạch	393.577 (69,2% của file thô)
Số người dùng khác nhau (đã làm sạch)	256.044
Số sản phẩm khác nhau (đã làm sạch)	67.554
Khoảng thời gian	tháng 10/1999 – tháng 10/2012

4.3 Phân bố lớp

Dữ liệu lệch mạnh về phía tích cực. Review positive chiếm khoảng 78%, negative 14,5% và neutral 7,6%, nên positive nhiều hơn neutral khoảng 10,3 lần. Một bộ phân loại luôn trả lời *positive* đạt khoảng 78% accuracy nhưng chỉ 0,29 Macro-F1, vì F1 của hai lớp còn lại bằng 0.

Đây là lý do Macro-F1 là độ đo chính (Mục 2.4), và vì sao cách chia là phân tầng và hàm mất mát có trọng số (Chương 5).

4.4 Độ dài văn bản

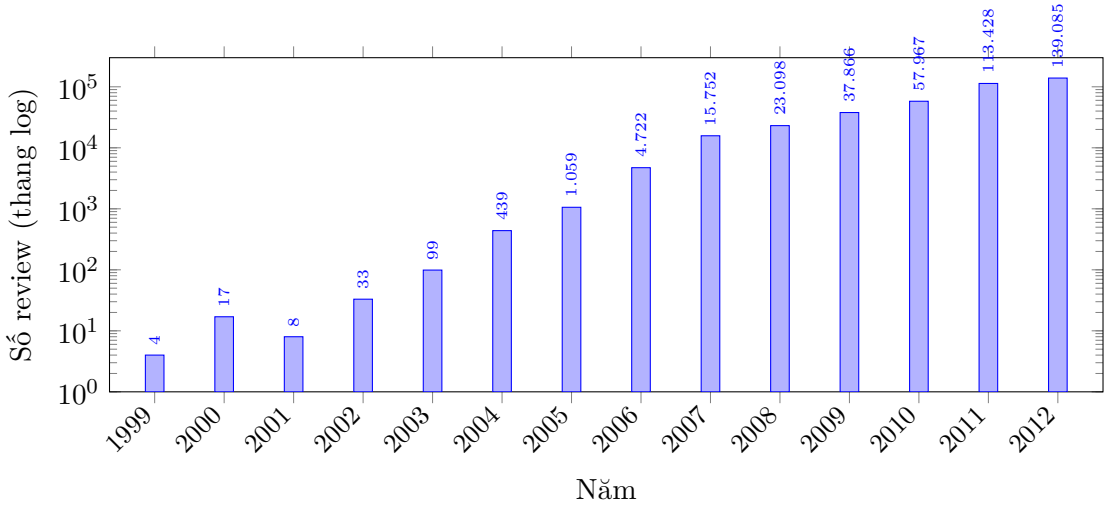
Độ dài review lệch phải mạnh: nội dung trung vị có 57 từ nhưng review dài nhất có 3.432 từ.

	Trung bình	Độ lệch chuẩn	Min	Trung vị	P90	P95	P99	Max
`Text` (từ)	79,8	77,2	3	57	159	215	377	3.432
`Summary` (từ)	4,1	2,6	0	3	8	9	12	42

Tiêu đề ngắn (trung vị 3 từ) nhưng cô đọng, ví dụ “Great taffy” hay “Not as Advertised”, nên tiêu đề được đặt trước nội dung để tạo đầu vào cho mô hình. Review 2 và 3 sao thường dài hơn review 5 sao, vì người viết giải thích cả điểm mạnh lẫn điểm yếu.

Giới hạn tối đa 200 từ bao phủ khoảng 93% review mà không phải cắt, nên được dùng làm giới hạn chuỗi cho BiLSTM. Với Transformer, giới hạn là 256 sub-word token; tỉ lệ review bị cắt (khoảng 6,2%) được đo ở Mục 6.4. Khi một review bị cắt, phần cuối bị mất còn phần đầu, nơi có tiêu đề, được giữ. Vì độ dài chênh lệch lớn, các batch dùng padding động và gom theo độ dài, để review ngắn không bị đệm tới độ dài của một review 3.000 từ.

4.5 Thay đổi theo thời gian



Số review đã làm sạch tăng gần theo cấp số nhân từ 2006, và hai năm 2011–2012 gộp lại có 252.513 review (64,2%); năm 2012 kết thúc ở tháng 10. Điểm sao trung bình giảm dần từ 4,386 năm 2007 xuống 4,112 năm 2012, và tỉ lệ negative tăng từ 10,0% lên 16,1%. Phân bố nhãn vì vậy không ổn định theo thời gian.

Cách chia ở Mục 5.5 là ngẫu nhiên, nên review train và test cùng một giai đoạn. Điều này không đo được mô hình sẽ làm tốt đến đâu trên review trong tương lai, và được nêu như một hạn chế.

4.6 Người dùng, sản phẩm và độ hữu ích

Có 256.044 người dùng và 67.554 sản phẩm khác nhau. Trong số người dùng, 80,3% chỉ viết một review, và 78,7% sản phẩm có từ năm review trở xuống. Cả hai phân bố đều có đuôi dài, nên mô hình không thể dựa vào thói quen chấm điểm của người dùng mà phải học từ văn bản.

Trong các review có ít nhất năm lượt bình chọn, review negative nhận nhiều lượt bình chọn hơn nhưng tỉ lệ hữu ích thấp hơn, vì người đọc thường không đồng ý với lời phàn nàn. Vì thông tin này không có sẵn khi review được đăng, nó không được dùng làm đặc trưng (Mục 3.5).

4.7 Nhiễu trong văn bản

Nhiễu trong `Text`	Tỉ lệ review
Thẻ HTML (chủ yếu ` `)	26,14%
URL (`http`, `www`)	2,08%
Ký tự HTML mã hoá (`&`, `"`)	0,33%

Vì vậy văn bản chỉ được làm sạch nhẹ (Mục 5.3). Từ dừng và dấu câu được *giữ lại*, vì các từ phủ định như *not*, *no*, *never* nằm trong danh sách từ dừng chuẩn nhưng lại quyết định cảm xúc, và vì các mô hình nơ-ron có thể học vai trò của từng từ từ ngữ cảnh.

4.8 Từ vựng của từng lớp

Đếm từ và cặp từ trên một mẫu cân bằng lớp gồm 20.000 review mỗi lớp (bỏ từ dừng trừ từ phủ định) cho thấy các từ đơn như *like*, *taste*, *good* và *coffee* xuất hiện ở cả ba lớp; *good* xuất hiện nhiều ngay cả trong review negative ("not good", "good but…"). Các cặp từ phân biệt lớp tốt hơn: *highly recommend*, *great product* và *love this* trong review positive; *waste money*, *would not* và *not buy* trong review negative. Lớp neutral không có từ vựng riêng mà trộn từ vựng của hai lớp kia, nên được dự đoán là lớp khó nhất.

4.9 Quyết định thiết kế cho bước chuẩn bị dữ liệu

Phát hiện	Quyết định
Khoảng 31% dòng thô là review lặp	Loại chúng trước khi chia
Nhãn lệch 77,9 / 14,5 / 7,6%	Chia phân tầng; trọng số lớp trong loss; Macro-F1 là độ đo chính
Độ dài lệch phải; 200 từ ≈ 93%	Giới hạn 200 từ (BiLSTM) và 256 token (Transformer); padding động và gom theo độ dài
Tiêu đề ngắn nhưng nhiều thông tin	Đầu vào là tiêu đề rồi đến nội dung
26% nội dung có HTML	Làm sạch nhẹ; giữ dấu câu và từ phủ định
Ngữ cảnh và phủ định quan trọng	Dùng mô hình chuỗi (BiLSTM với attention) và Transformer
Phân bố nhãn trôi theo thời gian	Nêu như một hạn chế; cách chia là ngẫu nhiên

Chương 5

Chuẩn bị dữ liệu

5.1 Mục tiêu

Biến các review thô thành một bộ dữ liệu cho mô hình không bị rò rỉ: làm sạch các dòng thô (Mục 5.2), tạo văn bản đầu vào (Mục 5.3) và nhãn (Mục 5.4), chia review thành ba phần (Mục 5.5) và tính trọng số lớp (Mục 5.6). Chương này thực hiện các quyết định thiết kế của Mục 4.9 bằng một cấu hình cố định:

Tham số	Giá trị	Nguồn gốc
Tỉ lệ chia train / val / test	80 / 10 / 10%	Phần test lớn; validation để chọn epoch
Phân tầng	Theo nhãn	Neutral chỉ chiếm 7,6% (Mục 4.3)
Seed ngẫu nhiên	42	Cách chia tái lập được
Giới hạn chuỗi	200 từ / 256 token	Độ phủ độ dài (Mục 4.4)

5.2 Làm sạch dữ liệu

Mỗi vấn đề chất lượng dữ liệu trước hết được đo trên toàn bộ file thô 568.454 dòng (các dòng có thể trùng giữa các quy tắc):

Vấn đề	Số dòng	Tỉ lệ dòng
Review lặp (cùng user, tên, thời điểm, nội dung)	174.521	30,70%
`Text` lặp	174.875	30,76%
Thiếu `Summary`	27	0,005%
Thiếu `ProfileName`	26	0,005%
Tử số > mẫu số (helpfulness)	2	<0,001%

Không có dòng nào trùng ở *tất cả* các cột, nên sự lặp lại ẩn trong mã sản phẩm. Ví dụ, người dùng `A395BORC6FGVXV` đăng một review 2 sao tiêu đề "Cough Medicine" lúc 1307923200, và review đó xuất hiện ba lần dưới ba mã sản phẩm khác nhau (`B000UA0QIQ`, `B002Y7526Y`, `B000U9WZ54`). Nếu giữ lại, các bản sao như vậy sẽ rơi vào cả hai phía của một phép chia ngẫu nhiên.

Việc làm sạch thực hiện theo thứ tự sau, luôn giữ lần xuất hiện đầu tiên:

1. Loại các dòng lặp khoá (`UserId`, `ProfileName`, `Time`, `Text`).
2. Loại các dòng có `HelpfulnessNumerator` > `HelpfulnessDenominator`, điều không thể xảy ra theo định nghĩa.

3. Loại các dòng có `Text` vẫn trùng với một dòng trước đó (bản sao giữa các tài khoản, spam).

4. Thay `Summary` bị thiếu bằng chuỗi rỗng và tạo nhãn từ `Score` (Mục 5.4).

Giai đoạn	Số dòng còn lại	Số dòng bị loại
File thô	568.454	–
Sau bước 1 (lặp khoá)	393.933	174.521
Sau bước 2 (helpfulness không hợp lệ)	393.931	2
Sau bước 3 (`Text` lặp)	393.577	354

Kết quả. Việc làm sạch loại 174.877 dòng (30,8% của 568.454) và còn lại **393.577 review**. Bước 3 giữ lần xuất hiện đầu tiên bất kể số sao. Nó cũng loại cả các review ngắn giống hệt nhưng do những người khác nhau viết, một sự đánh đổi có chủ ý: tốn 354 dòng (0,09% dữ liệu) và đóng nốt con đường rò rỉ còn lại. Bảng đã làm sạch được lưu một lần và mọi giai đoạn sau đều đọc từ đó.

5.3 Tạo văn bản đầu vào của mô hình

Đầu vào của mô hình là

$$\text{text} = \text{clean}(\texttt{Summary}) + \text{“. ”} + \text{clean}(\texttt{Text}),$$

trong đó clean giải mã các thực thể HTML, xoá thẻ HTML và URL, và gộp khoảng trắng. Nó không chuyển chữ thường, không xoá dấu câu và không xoá từ dừng (Mục 4.7). Dấu nối tuân theo ba quy tắc:

- Nếu tiêu đề không rỗng và không kết thúc bằng “.”, “!” hoặc “?”, hai phần được nối bằng “. ”.
- Nếu tiêu đề đã kết thúc bằng một trong các dấu đó, hai phần được nối bằng một khoảng trắng.
- Nếu tiêu đề rỗng (27 dòng thô thiếu tiêu đề), đầu vào chỉ là nội dung đã làm sạch.

Ví dụ, review có tiêu đề “Not as Advertised” trở thành “Not as Advertised. Product arrived labeled as Jumbo Salted Peanuts…”, và đoạn nội dung “…were bummed.

Now, because…” trở thành “…were bummed. Now, because…”. Làm sạch toàn bộ 393.577 review mất 19,5 giây. Việc token hoá phụ thuộc vào mô hình (từ điển từ cho BiLSTM, WordPiece cho Transformer), nên được thực hiện trong các chương xây dựng mô hình.

5.4 Tạo nhãn

Nhãn được suy ra từ `Score` theo phép ánh xạ ở Mục 2.2: 1 và 2 sao cho negative (0), 3 sao cho neutral (1), 4 và 5 sao cho positive (2).

5.5 Chia train, validation và test

Dữ liệu được chia hai giai đoạn có phân tầng với seed cố định: 80% cho train và 20% giữ lại, rồi phần giữ lại được chia đều thành validation và test.

```
train_df, temp_df = train_test_split(
    df[cols], test_size=0.2, stratify=df['label'], random_state=SEED)
val_df, test_df = train_test_split(
    temp_df, test_size=0.5, stratify=temp_df['label'], random_state=SEED)
```

Phần	Số review	negative	neutral	positive
Train	314.861	45.654	23.803	245.404
Validation	39.358	tỉ lệ như train		
Test	39.358	tỉ lệ như train		

Tỉ lệ khoảng 14,5%, 7,6% và 77,9% ở mọi phần vì cách chia có phân tầng. Train cập nhật trọng số. Validation chọn epoch tốt nhất và hiệu chỉnh ngưỡng neutral sau này. Test chỉ được dùng một lần, ở cuối, cho các kết quả báo cáo. Vì seed và quy tắc cố định, chạy lại cho ra đúng ba phần như cũ.

5.6 Trọng số lớp

Gọi N là số review train, $K = 3$ là số lớp và N_c là số review train của lớp c. Trọng số của lớp c là

$$w_c = \frac{N}{K\, N_c},$$

và hàm mất mát trên một batch là

$$\mathcal{L} = -\frac{1}{\sum_i w_{y_i}} \sum_i w_{y_i} \log \hat{p}_{i,y_i}.$$

Lớp hiếm nhận trọng số lớn, nên lỗi ở lớp đó bị phạt nặng hơn và gradient của nó không bị lớp đa số lấn át. Trọng số chỉ tính từ số lượng ở tập train:

Lớp	Số review train N_c	Trọng số w_c
negative	45.654	2,299
neutral	23.803	4,409
positive	245.404	0,428

Một review neutral nặng gấp khoảng 10 lần một review positive ($4{,}409/0{,}428 \approx 10{,}3$), đúng bằng tỉ lệ mất cân bằng ở Mục 4.3.

5.7 Phòng tránh rò rỉ và cách chia ngẫu nhiên

- **Văn bản lặp.** Review lặp bị loại *trước* khi chia (Mục 5.2), nên cùng một văn bản không thể nằm ở cả train và test.
- **Thống kê chỉ từ train.** Trọng số lớp tính từ tập train (Mục 5.6); từ điển của BiLSTM chỉ xây từ tập train (chương xây dựng mô hình).
- **Test chỉ dùng một lần.** Việc chọn epoch và ngưỡng neutral được làm trên validation; test chỉ được đọc cho báo cáo cuối.
- **Ngẫu nhiên, không theo thời gian.** Review train và test cùng giai đoạn, dù phân bố nhãn trôi theo thời gian (Mục 4.5). Vì vậy điểm số không đo hiệu năng trên review tương lai.
- **Không có kiểm tra tự động.** Tỉ lệ lớp của từng phần được in ra và so bằng mắt; không có lệnh assert, nên khi sửa code chia dữ liệu cần kiểm tra lại với bảng ở Mục 5.5.

5.8 Kết luận

568.454 review thô trở thành 393.577 review đã làm sạch, được chia thành 314.861 review train, 39.358 validation và 39.358 test, với trọng số lớp 2,299, 4,409 và 0,428 cho negative, neutral và positive. Các chương tiếp theo huấn luyện mô hình trên tập train, chọn trên validation và báo cáo trên test.

Chương 6

Xây dựng mô hình

6.1 Mục tiêu

Huấn luyện hai mạng nơ-ron trên cùng tập train và chấm chúng, cùng quy tắc "luôn đoán positive", trên cùng các review test (Chương 5): BiLSTM với attention huấn luyện từ đầu (Mục 6.3), và bộ mã hoá BERT được fine-tune trên dữ liệu (Mục 6.4). Quy tắc luôn đoán positive là mốc tham chiếu, không được huấn luyện. Mục 6.2 trước hết giải thích LSTM, BiLSTM, attention và BERT là gì và vì sao được dùng.

Cả hai mạng đều dùng cross-entropy có trọng số lớp của Mục 5.6, chọn cấu hình chỉ trên tập validation và đọc tập test một lần. Mọi con số trong chương này đến từ các lần chạy huấn luyện và validation; kết quả trên test nằm ở Chương 7.

6.2 Nền tảng: vì sao dùng mô hình chuỗi và Transformer

Mục này giới thiệu, ở mức độ các mục sau cần, các khái niệm đứng sau hai mô hình nơ-ron và lý do dùng từng mô hình trong bài toán này.

Vì sao thứ tự từ quan trọng

Một mô hình chỉ đếm từ và cặp từ không phân biệt được "not good" với "good" khi từ phủ định cách hai từ trở lên ("not really all that good"), và không biết ai được khen trong câu "the coffee was fine but the delivery was awful". Mục 4.8 cho thấy các từ đơn như *good* xuất hiện ở cả ba lớp, và các cặp từ phân biệt lớp tốt hơn. Một mô hình đọc review *theo thứ tự* và mang thông tin từ các từ trước sang các từ sau có thể dùng được ngữ cảnh này. Hai họ mô hình như vậy được sử dụng.

Mạng hồi quy và LSTM

Mạng hồi quy đọc từng từ một và giữ một trạng thái ẩn h_t tóm tắt mọi thứ đã đọc. Mạng hồi quy thuần làm mất thông tin trên văn bản dài, vì gradient dùng để huấn luyện nó co lại sau mỗi bước (vấn đề *vanishing gradient*). Đơn vị **Long Short-Term Memory** (LSTM) khắc phục điều này bằng một ô nhớ c_t và ba cổng quyết định cái gì được quên, cái gì được ghi và cái gì được xuất ra:

$$
\begin{aligned}
f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), & i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i),\\
o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), & c_t &= f_t \odot c_{t-1} + i_t \odot \tanh(W_c[h_{t-1}, x_t] + b_c),\\
h_t &= o_t \odot \tanh(c_t),
\end{aligned}
$$

trong đó x_t là vector của từ thứ t và σ là hàm logistic. Ô nhớ c_t chỉ thay đổi qua phép cộng và phép nhân từng phần tử với cổng, nên thông tin, và cả gradient, có thể đi qua nhiều từ. Vì vậy LSTM phù hợp với review dài từ vài chục đến vài trăm từ.

Vì sao hai chiều và vì sao attention

LSTM một chiều đọc từ trái sang phải, nên trạng thái tại một từ chỉ biết các từ đứng trước. **LSTM hai chiều** (BiLSTM) chạy thêm một LSTM từ phải sang trái và ghép hai trạng thái, $h_t = [\overrightarrow{h_t}; \overleftarrow{h_t}]$. Khi đó trạng thái tại mỗi từ phụ thuộc vào các từ ở cả hai phía, điều có ích khi nghĩa của một từ được quyết định bởi phần theo sau ("*good* … but not worth the price").

Cảm xúc của một review không do mọi từ mang như nhau. **Attention pooling** học một trọng số α_t cho từng vị trí và tạo vector review bằng tổng có trọng số của các trạng thái (công thức ở Mục 6.3), thay vì chỉ giữ trạng thái cuối, nơi các từ đầu yếu nhất. Các trọng số còn có thể hiển thị trên văn bản, làm mô hình có thể kiểm tra được.

BiLSTM với attention được chọn vì nó là mô hình chuỗi nhỏ, tiêu chuẩn cho bài toán cảm xúc, có thể huấn luyện từ đầu trên dữ liệu này trong vài phút, đọc ngữ cảnh theo cả hai chiều và có thể kiểm tra.

Transformer và BERT

Mạng hồi quy truyền thông tin từ từ này sang từ khác, nên hai từ ở xa chỉ liên kết với nhau qua nhiều bước. **Transformer** thay điều đó bằng *self-attention*: mỗi token so sánh trực tiếp với mọi token khác của review,

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V,$$

trong đó truy vấn Q, khoá K và giá trị V là các phép biến đổi tuyến tính của vector token. Nhiều *đầu* (head) như vậy chạy song song, và một vector cho vị trí của mỗi token được cộng vào vì tự thân self-attention bỏ qua thứ tự. Một chồng các lớp như vậy là một *bộ mã hoá* (encoder).

BERT (Bidirectional Encoder Representations from Transformers) là một bộ mã hoá Transformer đã được các tác giả của nó *tiền huấn luyện* trên lượng rất lớn văn bản tiếng Anh (Wikipedia và BookCorpus) mà không có nhãn cảm xúc nào. Nhiệm vụ của nó là đoán các từ bị che trong văn bản (masked language modelling) và đoán một câu có theo sau câu kia hay không. Điều này dạy mạng ngữ pháp, nghĩa của từ theo ngữ cảnh và các mẫu phủ định thường gặp. Văn bản được tách thành các sub-word WordPiece, nên một từ hiếm trở thành các mảnh đã biết (*unbelievable* → *un*, *##bel*, *##ie*, …) và không có từ nào là chưa biết. Token đầu tiên của mọi đầu vào là token đặc biệt `[CLS]`, có vector cuối đại diện cho cả văn bản.

Fine-tune là *học chuyển giao*: một lớp đầu ra nhỏ cho ba lớp được thêm lên vector `[CLS]`, và toàn bộ mạng đã tiền huấn luyện được huấn luyện thêm một chút trên các review có nhãn, với learning rate nhỏ để tri thức đã học được điều chỉnh chứ không bị xoá. Khác với BiLSTM, vốn học ngôn ngữ chỉ từ 315.000 review train, BERT bắt đầu với tri thức từ hàng tỉ từ, và dự án kiểm tra điều đó giúp được bao nhiêu. `bert-base-uncased` là cỡ nhỏ hơn trong hai cỡ gốc (12 lớp, 109 triệu tham số) và chuyển văn bản sang chữ thường, giúp cách thiết lập đơn giản.

6.3 BiLSTM với attention

Đầu vào

Văn bản đầu vào của Mục 5.3 được chuyển chữ thường và tách bằng một biểu thức chính quy giữ lại các dạng rút gọn (*don't*) và dấu `!` và `?`. Từ điển gồm các từ xuất hiện ít nhất ba lần trong tập train, giới hạn 50.000; kết quả có 46.760 mục, gồm cả ký hiệu padding và ký hiệu từ lạ. Nó phủ 99,71% số token train. Mỗi review bị cắt ở 200 từ, tức cắt 6,47% số review train.

Các batch 256 review được tạo bằng cách gom theo độ dài: dữ liệu được xáo trộn, chia thành các khối, sắp theo độ dài trong mỗi khối và cắt thành batch, để các review có độ dài gần nhau chung một batch và padding nhỏ. Mỗi epoch có 1.230 batch.

Kiến trúc

Lớp	Vai trò
Embedding 46.760×128	một vector học được cho mỗi từ, dropout 0,3
BiLSTM, 128 đơn vị mỗi chiều	đọc review từ trái sang phải và từ phải sang trái; trạng thái tại vị trí t là $h_t \in \mathbb{R}^{256}$
Attention pooling	gán trọng số cho mỗi vị trí và cộng các trạng thái
Dropout 0,3, Linear $256 \to 3$	điểm số các lớp

Lớp attention chấm điểm từng trạng thái, chuẩn hoá điểm trên các vị trí thật (không phải padding) và dùng tổng có trọng số làm vector review:

$$e_t = \mathbf{w}^\top h_t, \qquad \alpha_t = \frac{\exp(e_t)}{\sum_k \exp(e_k)}, \qquad \mathbf{c} = \sum_t \alpha_t h_t.$$

Các vị trí padding được gán điểm -10^9 trước softmax nên trọng số của chúng bằng không. Mô hình có 6.250.500 tham số huấn luyện được, trong đó 5.985.280 là embedding.

Huấn luyện

Thiết lập	Giá trị
Optimizer	AdamW, learning rate 2×10^{-3}, weight decay 10^{-4}
Lịch learning rate	giảm một nửa khi Macro-F1 validation không cải thiện
Cắt gradient	chuẩn 1,0
Epoch, early stopping	tối đa 5; dừng sau 2 epoch không cải thiện; giữ epoch tốt nhất
Seed	42

Lần chạy dùng đủ 5 epoch; Macro-F1 validation tốt nhất là 0,7504 ở epoch 4, và mô hình của epoch đó được giữ. Huấn luyện mất 3,4 phút trên một GPU Tesla T4.

Epoch	Loss train	Loss validation	Accuracy validation	Macro-F1 validation	Learning rate
1	0,6168	0,5283	0,8646	0,7275	0,002
2	0,4956	0,5292	0,8830	0,7469	0,002
3	0,4549	0,5049	0,8614	0,7318	0,002
4	0,4100	0,5376	0,8820	**0,7504**	0,001
5	0,3894	0,5342	0,8772	0,7469	0,001

Loss train giảm đều trong khi loss validation quanh 0,53 và thấp nhất ở epoch 3, dấu hiệu overfitting từ khoảng epoch 3 hoặc 4. Epoch được chọn theo Macro-F1, không theo loss validation, và chênh lệch giữa các epoch cuối (khoảng 0,003) là nhỏ.

6.4 Fine-tune BERT

`bert-base-uncased` là bộ mã hoá Transformer 12 lớp (kích thước ẩn 768, 12 đầu attention) được tiền huấn luyện trên Wikipedia và BookCorpus. Một lớp ba lớp mới được đặt lên biểu diễn của token `[CLS]` và toàn bộ mạng được huấn luyện. Cấu hình là một lần chạy duy nhất, không tìm kiếm siêu tham số.

Thiết lập	Giá trị
Token hoá	WordPiece, cắt ở 256 token; padding động và gom theo độ dài
Cắt bớt	khoảng 6,2% số review (đo trên 3.000 review train; độ dài trung vị 80, phân vị 90 là 207 token)
Batch, epoch	32 review, 2 epoch; 9.840 bước mỗi epoch, tổng 19.680
Optimizer	AdamW, learning rate 3×10^{-5}, weight decay 0,01 (không áp cho bias và LayerNorm)
Lịch learning rate	warm-up tuyến tính trong 10% bước đầu, rồi giảm tuyến tính về 0
Khác	fp16 mixed precision, cắt gradient 1,0, seed 42
Số tham số	109.484.547

Sau mỗi epoch mô hình được chấm trên tập validation và được lưu nếu Macro-F1 là tốt nhất từ trước đến giờ; không có early stopping. Mỗi epoch mất 32,2 phút trên Tesla T4, tổng 64,4 phút.

Epoch	Loss train	Accuracy validation	Macro-F1 validation
1	0,4943	0,8884	0,7664
2	0,3517	0,9069	**0,7864**

Macro-F1 validation vẫn đang tăng ở epoch cuối, nên mô hình chưa bão hoà và có thể tốt hơn nếu huấn luyện thêm epoch; với hai epoch thì chưa quan sát được overfitting.

6.5 Tóm tắt các mô hình

Mô hình	Huấn luyện trên dữ liệu này	Số tham số	Chọn trên validation
BiLSTM + attention	có, từ đầu	6,25 triệu	epoch, early stopping
BERT-base	có, fine-tune	109,48 triệu	epoch
Luôn đoán positive	không	0	–

Cả hai mạng đều được huấn luyện trên một GPU Tesla T4, nên thời gian huấn luyện của chúng so sánh được.

Chương 7

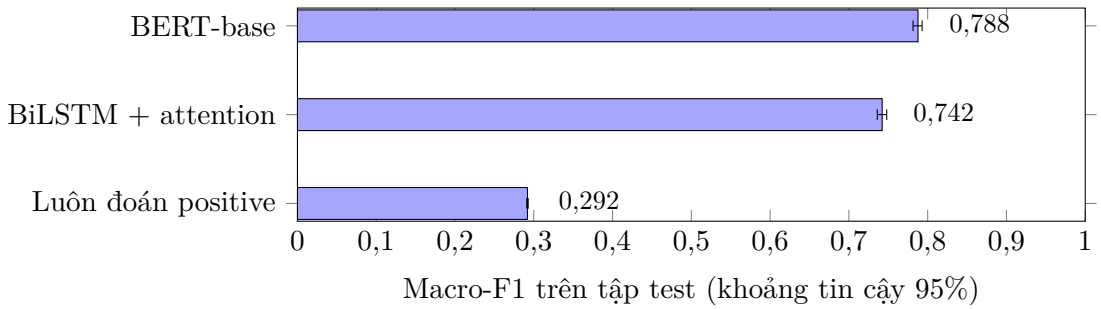
Đánh giá

7.1 Mục tiêu

Đo mỗi mô hình gán cảm xúc tốt đến đâu cho các review chưa từng thấy, so sánh hai mạng một cách công bằng và tìm chỗ chúng sai. Quy trình được cố định trước khi có kết quả: Macro-F1 (Mục 2.4) là độ đo chính; tập test gồm 39.358 review chỉ được đọc một lần; mọi lựa chọn (epoch, ngưỡng neutral) đều làm trên tập validation. Khoảng tin cậy đến từ 1.000 lần lấy mẫu bootstrap lại các review test, với mọi mô hình được chấm trên cùng một mẫu để các chênh lệch có thể ghép cặp. Các khoảng này chỉ phản ánh sai số lấy mẫu của tập test, không phản ánh việc chọn seed ngẫu nhiên.

7.2 Kết quả trên toàn bộ tập test

Mô hình	Accuracy	Macro-F1	F1 negative	F1 neutral	F1 positive	Macro-F1 khoảng 95%
BERT-base fine-tune	**0,9074**	**0,7877**	**0,8470**	**0,5540**	**0,9620**	[0,7814; 0,7929]
BiLSTM + attention	0,8788	0,7422	0,7863	0,4916	0,9488	[0,7360; 0,7480]
Luôn đoán positive	0,7794	0,2920	0	0	0,8760	[0,2911; 0,2929]



Cả hai mạng cao hơn hẳn quy tắc luôn đoán positive (Macro-F1 0,292, đạt accuracy 0,78 mà không nhận biết được gì về hai lớp còn lại). BERT tốt nhất ở mọi cột. F1 của lớp neutral thấp nhất với cả hai mạng, 0,49 và 0,55.

Chi phí. Cả hai mạng đều được huấn luyện và đo thời gian trên Tesla T4.

Mô hình	Thời gian huấn luyện	Suy luận trên tập test	Số tham số
BERT-base	64,4 phút	83,7 s	109,48 triệu
BiLSTM + attention	3,4 phút	3,7 s	6,25 triệu

BERT cần khoảng 19 lần thời gian huấn luyện, 23 lần thời gian suy luận và 17,5 lần số tham số của BiLSTM để có thêm 0,0455 Macro-F1. BiLSTM đạt khoảng 94% Macro-F1 của BERT với khoảng 5% thời gian huấn luyện của nó.

7.3 Có phải lớp neutral là vấn đề?

Cả hai mạng đều có recall cao nhưng precision thấp ở neutral: chúng dự đoán neutral cho quá nhiều review. Bảng cho biết, với mỗi mô hình, tỉ lệ review neutral thật được dự đoán đúng, và nhãn thật của các review mà nó dự đoán là neutral.

	Neutral thật được đoán là			Review đoán neutral thật ra là		
Mô hình	negative	neutral	positive	negative	neutral	positive
BERT-base	19,7%	68,1%	12,1%	17,9%	46,7%	35,4%
BiLSTM + attention	16,5%	67,6%	15,9%	23,4%	38,6%	38,0%

Cả hai mạng tìm lại được khoảng hai phần ba số review neutral, nhưng chưa đến một nửa số review chúng gọi là neutral thật sự là neutral. Nguyên nhân một phần nằm ở dữ liệu (review 3 sao thường vừa khen vừa chê, và lớp neutral không có từ vựng riêng, Mục 4.8) và một phần ở hàm mất mát, có trọng số neutral gấp 4,4 lần một trọng số điển hình (Mục 5.6).

7.4 Hiệu năng theo độ dài review

Số từ mỗi review	≤30	31–60	61–100	101–200	201–400	>400
Số review trong tập test	6.137	13.659	9.601	7.534	2.100	327
BERT-base	0,778	0,783	0,794	0,796	0,758	0,693
BiLSTM + attention	0,753	0,738	0,746	0,747	0,704	0,600

Cả hai mô hình đều thấp nhất ở review dài hơn 400 từ, và BiLSTM giảm nhiều nhất (0,600 so với 0,693 của BERT). BiLSTM chỉ giữ 200 từ đầu và BERT giữ 256 token đầu, nên cả hai đều mất phần cuối của review dài. Nhóm cuối chỉ có 327 review nên điểm dao động nhiều hơn và không nên đọc quá kỹ.

7.5 Khoảng bootstrap cho chênh lệch

Chênh lệch Macro-F1 giữa BERT và BiLSTM trên toàn bộ tập test là +0,0454, với khoảng 95% là [+0,0400; +0,0507] trên các mẫu bootstrap ghép cặp. Khoảng này không chứa số không, nên chênh lệch lớn hơn sai số lấy mẫu của tập test, và BERT hơn BiLSTM trong 100% số mẫu.

7.6 Hiệu chỉnh ngưỡng cho lớp neutral

Vì các mô hình dự đoán neutral quá nhiều, một hằng số `bias` được cộng vào log-xác suất của neutral trước khi lấy arg max (bias âm làm dự đoán neutral ít hơn). Bias được chọn trên tập validation để cực đại Macro-F1 rồi áp một lần lên tập test. Việc này không cần huấn luyện lại.

Mô hình	Bias đã chọn	Macro-F1 validation trước → sau	Macro-F1 test trước → sau	F1 neutral test trước → sau
BiLSTM + attention	−0,8	0,7504 → 0,7577	0,7422 → 0,7551	0,4916 → 0,4978
BERT-base	−1,1	0,7864 → 0,7902	0,7877 → 0,7866	0,5540 → 0,5448

Việc chỉnh giúp BiLSTM (+0,013 trên tập test) nhưng không giúp BERT: mức tăng 0,004 mà BERT có trên validation không lặp lại trên test và nằm trong nhiễu. Các kết quả chính của báo cáo không dùng bias (Mục 7.2); việc hiệu chỉnh là một thí nghiệm thêm.

7.7 Phân tích lỗi và ví dụ

Các lỗi tự tin của mô hình tốt nhất

BERT dự đoán *negative* cho 165 review 5 sao và *positive* cho 58 review 1 sao; 948 review neutral bị phân loại sai. Nhiều lỗi tự tin trông như nhãn nhiễu: tác giả chấm 5 sao nhưng viết lời phàn nàn ("Now I would not recommend it to my worst enemy. The coffee now has no aroma…", "Incredibly overpriced…this is a total and complete rip off"), hoặc chấm 1 sao mà lại khen ("LOVE LOVE LOVE THESE! (edited because NO longer available in prime)"). Trong các trường hợp này mô hình đọc văn bản đúng hơn số sao. Không phải ca nào cũng vậy: "My dogs won't eat anything else. My dogs will not eat anything but the Iams biscuit" khen sản phẩm, và mô hình đọc sai. Tỉ lệ nhãn nhiễu trong các lỗi chưa được đếm, nên báo cáo không nêu tỉ lệ.

Một đặc tính liên quan của dữ liệu: khoảng 3,4% review test (1.350) chứa cụm như "3 stars", và chỉ khoảng 59% trong số đó nêu đúng số sao thật (phần còn lại là cách nói như "5 star service" hay "4 stars out of 5"). Các văn bản này được giữ lại, nên có một ít tín hiệu đi từ nhãn vào văn bản với cả hai mô hình.

Các câu tự viết để thử

Sáu câu do tác giả viết cho một kiểm tra định tính; chúng không thay thế các phép đo ở trên.

Câu	BiLSTM	BERT
"This coffee is absolutely amazing, I will definitely buy it again!"	pos (100%)	pos (100%)
"Not bad at all, actually pretty tasty."	neu (78%)	pos (79%)
"It's okay. Nothing special, but it does the job."	neu (100%)	neu (99%)
"Great, another box arrived completely crushed. Just what I needed."	pos (87%)	pos (99%)
"My dog loves these treats, but they are way too expensive for such a small bag."	neu (84%)	neu (89%)
"I would not recommend this to anyone. Total waste of money."	neg (100%)	neg (100%)

Cả hai mô hình đều đọc câu mỉa mai thứ tư là positive, vì "great" và "just what I needed" nghe như khen. Cả hai gán neutral cho các câu pha trộn (thứ ba và thứ năm) và đoán đúng các câu rõ ràng khen hoặc chê. Với câu thứ hai, BiLSTM trả lời neutral còn BERT trả lời positive; cả hai đều chấp nhận được cho một lời khen nhẹ như vậy. Trọng số attention của BiLSTM chủ yếu rơi vào các từ mang cảm xúc hoặc đảo nghĩa (*mistake*, *great*, *not*, *okay*, *but*), nhưng không phải lúc nào cũng vậy: với một review neutral, trọng số lớn nhất rơi vào một tên sản phẩm (*stevia*). Attention cho thấy mô hình nhìn vào đâu, không phải một lời giải thích đầy đủ.

7.8 Hạn chế

- **Nhãn yếu.** Số sao không phải lúc nào cũng khớp với văn bản (Mục 7.7), và ranh giới 3 sao mang tính chủ quan, điều này chặn trên chất lượng mà bất kỳ mô hình nào có thể cho thấy.
- **Mỉa mai và ý kiến pha trộn.** Cả hai mô hình đều sai ở câu mỉa mai, và neutral vẫn là lớp khó nhất (F1 0,49 và 0,55).
- **Chia ngẫu nhiên.** Phân bố nhãn trôi theo thời gian (Mục 4.5) và cùng một người dùng hoặc sản phẩm có thể nằm ở cả train và test, nên điểm số không đo hiệu năng trên review tương lai.

- **Số lần chạy và seed.** Mỗi mô hình chỉ được huấn luyện một lần (seed 42), nên các khoảng bootstrap không bao gồm dao động giữa các seed.
- **BERT chưa bão hoà.** Nó được fine-tune 2 epoch với một cấu hình cố định, nên điểm của nó có thể là cận dưới.
- **Cắt bớt khác nhau.** BiLSTM giữ 200 từ và BERT giữ 256 token.
- **Một lĩnh vực.** Toàn bộ dữ liệu là review thực phẩm tiếng Anh trên Amazon, 1999–2012.

Chương 8

Kết luận

8.1 Tổng kết

Dự án đã biến 568.454 review thực phẩm Amazon thành một bộ dữ liệu 393.577 review sạch, không rò rỉ (Chương 5), chia 80/10/10 có phân tầng, và so sánh hai bộ phân loại đã huấn luyện với quy tắc luôn đoán positive trong bài toán cảm xúc ba lớp gán nhãn từ số sao.

- **BERT-base được fine-tune là mô hình tốt hơn:** Macro-F1 0,7877 và accuracy 0,9074 trên 39.358 review test, hơn BiLSTM với attention (0,7422) là 0,0455, với khoảng 95% của chênh lệch là [+0,0400; +0,0507]. Nó hơn ở cả ba lớp, nên học chuyển giao tốt hơn học từ đầu trong bài toán này.
- **Neutral là điểm yếu của cả hai mô hình** (F1 0,49 và 0,55): chúng dự đoán nó quá nhiều, và dịch ngưỡng chỉ giúp BiLSTM.
- **Chi phí.** BERT cần gấp 19 lần thời gian huấn luyện và 17,5 lần số tham số của BiLSTM để có thêm 0,0455 Macro-F1.

8.2 Hạn chế

Các hạn chế được liệt kê cùng số đo ở Mục 7.8. Quan trọng nhất là: nhãn sao không phải lúc nào cũng khớp với văn bản; cách chia ngẫu nhiên không đo hiệu năng trên review tương lai; mỗi mô hình chỉ chạy một lần; và mô hình BERT chỉ được fine-tune hai epoch, với Macro-F1 validation vẫn đang tăng.

8.3 Hướng phát triển

1. **Fine-tune BERT lâu hơn hoặc lặp lại** (nhiều epoch hơn, nhiều seed), và các bộ mã hoá mạnh hơn như RoBERTa-base hay DeBERTa-v3, để kiểm tra điểm của BERT có phải là cận dưới không.
2. **Chia theo thời gian** (huấn luyện đến 2011, kiểm tra trên 2012) để đo hiệu năng trên review sau này và ảnh hưởng của việc phân bố nhãn trôi.
3. **Vector từ tiền huấn luyện** (GloVe, fastText) cho embedding của BiLSTM, để xem khoảng cách với BERT có thu hẹp không.
4. **Các cách xử lý mất cân bằng khác** (focal loss, oversampling), vì trọng số neutral lớn có thể gây việc dự đoán neutral quá nhiều.
5. **Cắt đầu và đuôi** cho review dài, nơi cả hai mô hình đạt điểm thấp nhất.

6. **Một mẫu nhỏ do con người gán nhãn**, không dựa vào số sao, để đo bao nhiêu lỗi là do nhãn nhiễu.

8.4 Khả năng tái lập

Cách chia dùng seed và quy tắc cố định, và mọi dự đoán trên tập test đều được lưu, nên mọi bảng ở Chương 7 có thể tính lại từ đó. Mã nguồn gồm một notebook (làm sạch, tìm hiểu và chuẩn bị dữ liệu, BiLSTM, BERT và đánh giá) và một gói dùng chung `src/`.

Tài liệu tham khảo

[1] J. McAuley and J. Leskovec. From amateurs to connoisseurs: modeling the evolution of user expertise through online reviews. In *Proceedings of the 22nd International Conference on World Wide Web (WWW)*, 2013.

[2] Stanford Network Analysis Project. Amazon Fine Food Reviews (bộ dữ liệu Kaggle `snap/amazon-fine-food-reviews`). https://www.kaggle.com/datasets/snap/amazon-fine-food-reviews.